Détection automatique du profil psychologique MBTI

par Kexin Gui & Yidi Huang

Introduction

Notre projet se penche sur un défi intrigant à la jonction de la psychologie et du modèle linguistique. En se concentrant sur le Myers-Briggs Type Indicator (MBTI), un instrument d'évaluation psychologique reconnu, notre objectif est d'explorer la possibilité de détecter automatiquement les types de personnalité MBTI via l'analyse textuelle. Notre principale problématique est de savoir si un modèle linguistique développé en anglais peut être généralisé à un corpus en français pour détecter les types de personnalité MBTI à travers l'analyse textuelle. Sur la base de cette interrogation, nous avons formulé trois hypothèses complémentaires.

Premièrement, nous évaluons si les données issues de Twitter fournissent des indices suffisants pour une détection efficace du MBTI. Cette approche repose sur l'idée que les interactions sur les réseaux sociaux peuvent révéler des aspects significatifs des types de personnalité. Deuxièmement, nous examinons la correspondance entre les données textuelles et les scores de personnalité MBTI obtenus via des questionnaires traditionnels, cherchant à comprendre dans quelle mesure les expressions écrites reflètent les traits de personnalité évalués par le MBTI. Enfin, inspirés par les travaux de Plank, B., et Hovy, D. (2015), nous intégrons une quatrième hypothèse liée à l'analyse textuelle : l'impact de la suppression des mots vides sur la performance du module de détection. Cette considération technique vise à affiner notre compréhension des mécanismes sous-jacents dans la détection automatique du profil MBTI et souligne l'importance des nuances linguistiques dans le traitement du langage naturel.

Dans le cadre de notre projet, d'abord nous avons réalisé une synthèse de l'article que nous avions référencé, en nous inspirant de leur analyse des types de personnalité MBTI ainsi que de leurs résultats de recherche. Ensuite, nous avons construit un corpus en langue française, en suivant les méthodes décrites par les auteurs de cet article. Cette étape était essentielle pour assurer la pertinence et la précision de notre recherche, le corpus étant la fondation sur laquelle repose notre étude. La troisième étape a consisté à reproduire un modèle linguistique existant. Cette reproduction était nécessaire pour adapter le modèle à notre corpus spécifique et à nos objectifs de recherche. Enfin, nous avons mis en place un modèle de transformer pour accomplir la tâche de détection automatique des traits psychologiques MBTI.

I. Définition du MBTI

Le Myers-Briggs Type Indicator (MBTI) constitue un instrument psychométrique conçu pour quantifier et classifier les préférences comportementales et de personnalité des individus. Fondé sur la théorie des types psychologiques de Carl Jung, ce modèle a été élaboré par Isabel Myers et Katharine Briggs au milieu du XXe siècle. Le MBTI trouve son application dans divers contextes, notamment le développement personnel, la gestion des ressources humaines, le conseil en orientation professionnelle, la psychothérapie et le domaine éducatif.

Le MBTI repose sur quatre axes binaires fondamentaux, représentant des dichotomies de préférences personnelles :

Extraversion (E) vs. Introversion (I) : Cette dimension examine la source d'énergie privilégiée par l'individu. Les extravertis, orientés vers le monde extérieur, trouvent leur énergie dans les interactions sociales, tandis que les introvertis, tournés vers leur monde intérieur, puisent leur énergie dans les réflexions et moments de solitude.

Sensation (S) vs. Intuition (N) : Elle éclaire sur la manière dont les individus perçoivent les informations. Les personnes à dominante Sensation se concentrent sur les données concrètes et actuelles, en s'appuyant sur l'expérience vécue. En revanche, celles avec une préférence pour l'Intuition privilégient les possibilités, les concepts abstraits, en se fiant à l'inspiration.

Pensée (T) vs. Sentiment (F) : Cet axe est centré sur le processus de prise de décision. Les individus orientés vers la Pensée prennent des décisions basées sur une analyse logique et objective, tandis que ceux orientés vers le Sentiment prennent des décisions guidées par des valeurs personnelles et la recherche de l'harmonie sociale.

Jugement (J) vs. Perception (P) : Cette dimension reflète l'approche globale de la vie. Les personnes avec une tendance au Jugement préfèrent un mode de vie structuré et des décisions planifiées, alors que celles à dominante Perception privilégient la flexibilité et l'ouverture à de nouvelles informations et expériences.

En définitive, le MBTI dépasse la simple catégorisation des traits de personnalité pour offrir un cadre analytique permettant de mieux comprendre et apprécier la diversité des profils humains.

II. Synthèse de l'article

Pour aborder les trois hypothèses précédemment énoncées, les auteurs ont suivi une démarche en trois étapes distinctes : la conception des jeux de données, la formulation du guide d'annotation, et enfin, l'évaluation des deux premières hypothèses avec des régressions de leur modèle.

1) Construction des jeux de données

Les auteurs ont exploité deux ensembles de données dans leur recherche. Le premier, appelé comme MBTI-Twitter, est préexistant et englobe des tweets en anglais associés à des profils psychologiques correspondants. Afin d'assurer une représentation équilibrée des différentes personnalités, les auteurs ont sélectionné au hasard six utilisateurs pour chacune des 16 personnalités, totalisant ainsi 96 échantillons. Pour chaque échantillon, les dix premiers tweets ont été conservés, garantissant ainsi la longueur et la taille homogène de chaque exemple.

Quant au deuxième ensemble de données, il a été spécifiquement conçu par les auteurs à l'aide de la plateforme de crowdsourcing Amazon MTurk. Ils ont soumis un questionnaire via cette plateforme pour recueillir des réponses, comprenant des informations sur le type de MBTI de la personne, ses préférences en termes de vacances et de passe-temps, ainsi que des justifications. Afin de maintenir la taille de chaque échantillon similaire à celle des données Twitter, les auteurs ont imposé une exigence de 300 caractères minimum pour chaque réponse. Parmi les réponses recueillies, ils en ont sélectionné six pour chaque type de MBTI.

2) Annotation

Les auteurs ont entamé le processus d'annotation visant à identifier la personnalité. Deux annotateurs ont été recrutés pour la tâche, l'un titulaire d'un doctorat en psychologie et l'autre en linguistique informatique. Ces deux annotateurs ont suivi une formation intensive de six mois en préparation de la tâche d'annotation.

Ils ont développé un guide d'annotation visant à repérer les indicateurs linguistiques dans les quatre dimensions.

E et I:

Conformément à leur guide, les individus extravertis mentionnent plus fréquemment de nouvelles personnes et des activités sociales telles que des soirées et des danses dans leurs réponses, en utilisant fréquemment le pronom "nous". En revanche, les introvertis évoquent plus souvent leurs amis et proches, privilégient le pronom "je".

N et S:

Dans la dimension sensation et intuition, les personnes de type "sensation" ont tendance à recourir à davantage d'adjectifs et d'adverbes pour détailler leurs descriptions. Leur préférence réside dans les activités techniques telles que l'escalade ou les casse-tête, impliquant une approche plus concrète, avec un style d'écriture clair et concis. En contraste, les individus de type "intuition" se tournent vers des activités plus imaginatives comme la littérature et la musique, rédigent des textes plus longs et complexes.

F et T:

Pour la dimension pensée et sentiment, les auteurs indiquent que les individus de type "pensée" ont tendance à recourir à des opinions et des comparaisons pour justifier directement leurs propos. En revanche, les personnes de type "sentiment" privilégient des justifications plus détournées, en évoquant des personnes et des sentiments.

Jet P:

En ce qui concerne la dimension jugement et perception, les individus de type "jugement" ont une inclination pour la planification. Ils adoptent généralement une approche plus stricte dans l'utilisation des temps verbaux. En contraste, ceux de type "perception" ont tendance à préférer l'utilisation du présent et leur style d'écriture est souvent moins formel que celui des individus de type "jugement".

3) Évaluation des hypothèses et des difficultés

En suivant le guide d'annotation, les annotateurs ont procédé à l'annotation et obtenu les résultats présentés dans l'image1. Ces résultats confirment notre première hypothèse (H1) selon laquelle les messages Twitter ne contiennent pas toujours des signaux linguistiques permettant la détection de la personnalité.

Statistic		MBTI-	Twitte	r	MBTI-MTurk			
Statistic	EI	SN	TF	JP	EI	SN	TF	JP
Both annotators confident	53	30	43	15	62	54	38	69
Annotators agree	46	81	61	50	100	69	62	78
Annotator A agrees with the gold label	77	64	64	53	78	54	77	44
Annotator B agrees with the gold label	47	44	54	47	60	54	85	42
Both annotators agree with the gold label	77	54	57	50	75	62	54	43

image1

Dans l'ensemble de données MBTI-Twitter, les annotateurs sont en accord sur la dimension EI dans 46 % des cas et sur la dimension JP dans 50 % des cas. En revanche, dans l'ensemble de données MBTI-MTurk, les annotateurs sont en accord sur ces deux dimensions dans 100 % et 78 % des cas. Cependant, en calculant le

pourcentage de cas où GOLD correspond aux annotations des deux annotateurs, on constate que cela ne représente que 50 % des cas pour la dimension JP.

Ces résultats suggèrent que, malgré un accord inter-annotateur élevé, les signaux linguistiques pour la dimension JP capturés à partir du texte ne correspondent pas correctement aux résultats basés sur un QCM officiel.

De plus, ces données indiquent que la dimension EI est la seule pour laquelle une association notable a été trouvée entre l'évaluation du MBTI basée sur le QCM traditionnel et l'évaluation basée sur l'analyse textuelle, confirmant ainsi la deuxième hypothèse (H2) pour trois des quatre dimensions du MBTI.

III. Construction du corpus français

La construction de notre corpus français a été une étape cruciale dans notre projet de détection automatique du profil psychologique MBTI. Ce corpus se divise en deux parties distinctes : le Corpus de questionnaire et le Corpus de Twitter.

Corpus de Questionnaire

Nous avons adopté le questionnaire utilisé par les chercheurs dans l'article de référence, en l'adaptant pour répondre aux besoins spécifiques de notre recherche. En particulier, pour les deux dernières questions, nous avons imposé une longueur minimale de réponse de 200 caractères. Cette contrainte avait pour objectif de capturer suffisamment de signaux linguistiques pour notre analyse. La sélection de ces questions se basait sur l'hypothèse que la manière dont les individus occupent leur temps libre reflète le plus naturellement leur personnalité.

Pour la collecte de données, nous avons sollicité des camarades de classe, des utilisateurs sur les médias sociaux, ainsi que des amis et des connaissances pour répondre au questionnaire. Comme l'illustre ce diagramme en secteurs, nous avons recueilli un total de soixante-dix-sept réponses. Dans notre corpus, "Natif" désigne des personnes qui utilisent couramment le français dans leur vie quotidienne et sur les réseaux sociaux, tandis que "non_natif" fait référence à des amis chinois parlant français.

Un contrôle rigoureux de la qualité a été appliqué à toutes les réponses collectées. Nous avons filtré celles qui étaient trop courtes ou incompréhensibles. De plus, si les répondants mentionnent leur type de MBTI dans leurs réponses, ces informations sont supprimées pour éviter de biaiser l'annotation manuelle et l'apprentissage automatique. Après ce processus de vérification, nous disposions de 65 échantillons utiles pour notre étude.

Corpus de Twitter

Pour le volet Twitter de notre corpus, nous avons recherché des utilisateurs représentant les 16 types de personnalité MBTI. Par exemple, nous avons utilisé des recherches comme « Je suis ENTP/INTJ » pour identifier des utilisateurs correspondant à ces profils. Nous avons ensuite collecté 3 à 4 tweets par utilisateur, en veillant à ce que chaque extrait de corpus ait une longueur comparable aux réponses du questionnaire. Durant cette phase de collecte, un nettoyage des données a été effectué, incluant la suppression des liens, des mentions d'autres utilisateurs et des émojis.

En somme, la construction de ce corpus bilingue et diversifié a été un processus minutieux, visant à assurer la richesse et la variété des données nécessaires pour notre analyse en détection automatique du profil MBTI.

IV. Reproduction du modèle linguistique

Pour reproduire le modèle linguistique présenté dans l'article, nous utiliserons leur guide d'annotation sur notre propre corpus. Cependant, tandis que le corpus de Twitter est équilibré, ce n'est pas le cas pour le corpus du questionnaire.

Il est observé que dans les 4 dimensions, les paires de dimensions (Sensation et intuition, Pensée et sentiment) présentent un déséquilibre dans le nombre d'échantillons, avec un type représentant presque quatre fois l'autre (image2). C'est pourquoi le calcul des résultats pondérés est prévu ultérieurement.

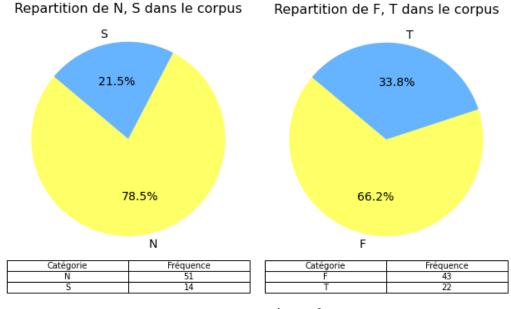
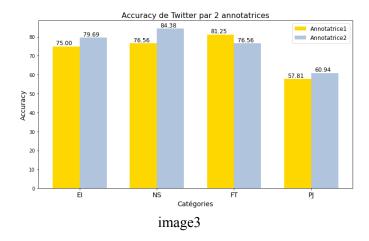


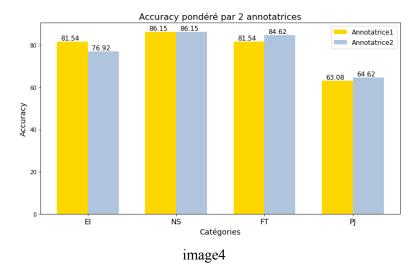
image 2

1) Accuracy

Tout d'abord, l'étude s'attaque à l'accuracy de l'annotation pour les deux corpus. Pour le corpus Twitter, nous constatons un taux d'exactitude d'environ 80%, avec une baisse notable de 20% dans la dimension JP. (image3)



En ce qui concerne le corpus du questionnaire, le score est pondéré et il est évident qu'il y a une amélioration d'environ 5% dans chaque dimension. Cependant, une baisse significative persiste dans la dimension JP, ce qui corrobore la conclusion de l'article selon laquelle JP est difficile à repérer en termes de signaux linguistiques pour la détection du profil psychologique. (image4)



2) Accord inter-annotateurs

Conformément à l'article, un tableau a été créé pour offrir une vue claire sur l'accord inter-annotateur. Il est observé notamment que dans plusieurs cas, l'accord entre deux annotateurs ne correspond pas au GOLD dans la dimension JP.

Les tableaux plus détaillés ont été construits et la cohérence kappa a été calculée. Il est à noter que, dans le corpus Twitter, bien que la précision soit la plus basse parmi les quatre dimensions, le coefficient kappa est le plus élevé. Cette observation peut être attribuée à la nature particulière des tweets et aux limites des règles d'annotation.

Quant au corpus du questionnaire, des résultats plus favorables sont obtenus, indiquant que les échantillons du questionnaire s'alignent mieux sur les règles d'annotation.

3) Précision, Rappel, F-mesure

Dans le cadre de notre projet, une analyse rigoureuse de la précision, du rappel et du F-score a été effectuée pour évaluer la qualité de l'annotation des questionnaires et des textes Twitter relatifs aux dimensions du MBTI. Nous avons initié ce processus par le calcul séparé des scores pour deux annotateurs, avant de procéder à la moyennisation de ces résultats afin d'obtenir une mesure fiable de la performance globale.

Selon les résultats obtenus à partir de l'annotation du questionnaire, la dimension EI a démontré la précision la plus élevée avec un score de 0,84, tandis que la dimension JP a enregistré la précision la plus basse avec un score de 0,57. Ces données suggèrent que les annotateurs trouvent plus aisé de discerner les éléments linguistiques associés à la dimension EI, tandis que l'identification des signaux relatifs à la dimension JP s'avère plus ardue.

Matrice					Matrice				
	El	SN	TF	JP		EI	SN	TF	JP
Précision	0.77	0.81	0.68	0.61	Précision	0.84	0.8	0.81	0.57
Rappel	0.77	0.8	0.66	0.59	Rappel	0.76	0.8	0.81	0.53
F-score	0.77	0.8	0.66	0.58	F-score	0.76	0.79	0.81	0.51

image 5(gauche): Précision, Rappel et F-score d'annotation Twitter

image 6(droite): Précision, Rappel et F-score d'annotation Questionnaire

Lors de l'application des mêmes critères d'évaluation aux textes issus de Twitter, nous avons observé une baisse générale de la précision pour les quatre dimensions, ce qui implique que le contexte des tweets pourrait présenter des défis supplémentaires dans la détection des traits de personnalité.

Les écarts observés entre les scores de précision des corpus de questionnaire et de Twitter reflètent les difficultés inhérentes à l'annotation manuelle, qui peuvent être exacerbées par la brièveté et la nature souvent elliptique du langage utilisé sur les réseaux sociaux. Cela souligne l'importance de développer des modèles d'annotation et des algorithmes de machine learning qui sont finement ajustés pour traiter et interpréter les spécificités linguistiques de chaque dimension du MBTI.

4) Reculs du modèle

Selon des résultats obtenus de notre analyse de données, nos deux premières hypothèses ont été corroborées.

Les données issues de Twitter peuvent ne pas contenir suffisamment de signaux pour une détection fiable de la personnalité MBTI. Les contraintes inhérentes à ce média, telles que la limite de caractères et le style de communication informel, peuvent restreindre la gamme des expressions comportementales et linguistiques nécessaires pour un diagnostic précis.

Il est également plausible que les données textuelles ne soient pas parfaitement alignées avec les résultats des scores de personnalité MBTI obtenus par le biais de questionnaires.

Nous adhérons aux deux premières hypothèses précédemment énoncées, reconnaissant les limites intrinsèques du guide d'annotation proposé par l'auteur initial. Ces limites se manifestent notamment par la présence de réponses ambivalentes, situées dans la zone médiane du spectre MBTI, ou exprimant des traits de

personnalités diamétralement opposés. Cette réalité reflète la fluidité des préférences personnelles, qui sont susceptibles de varier au fil du temps et des circonstances, rendant ainsi la standardisation des critères d'annotation particulièrement complexe.

Sur le plan culturel, les signaux linguistiques dérivés de l'étude principale présentent des caractéristiques spécifiquement anglophones. Cette constatation soulève la question de la pertinence de ces indicateurs dans des contextes culturels variés, notamment au sein de la francophonie où des loisirs tels que l'art, la musique ou la littérature sont couramment cités par des personnalités contrastées, suggérant ainsi une généralisation de ces centres d'intérêt.

De plus, l'analyse de notre corpus de locuteurs natifs chinois révèle une tendance à l'introversion plus marquée chez ces derniers, en contradiction avec les signaux linguistiques initialement proposés, où l'extraversion est souvent associée à des activités sociales élargies. Par contraste, dans notre corpus, les individus dits extravertis mentionnent fréquemment des activités en petit comité, telles que des sorties avec des amis ou en famille, tandis que les introvertis expriment une préférence pour les activités solitaires ou domestiques.

Cette divergence culturelle est encore plus prononcée chez les locuteurs non-natifs qui, lors de la réponse aux questionnaires, peuvent se focaliser davantage sur des aspects structurels de la langue, tels que la grammaire et la conjugaison. Cette tendance influence la manifestation des traits de personnalité, en particulier dans la dimension JP, où la distinction entre Jugement et Perception peut être obscurcie par l'attention portée à la forme linguistique plutôt qu'au contenu.

En somme, nos observations soulignent l'importance d'adapter les modèles d'annotation au contexte culturel spécifique des répondants, et de tenir compte des variations individuelles et culturelles qui influencent la manifestation des préférences de personnalité.

V. Utilisation du modèle

Après la reproduction du modèle linguistique, des modèles informatiques ont été expérimentés pour la détection du profil psychologique. Les données collectées précédemment ont été utilisées, avec un accent particulier mis sur les étapes suivantes.

1) Prétraitement des données

Dans cette étape, trois tâches ont été accomplies. Tout d'abord, le nettoyage du corpus a été effectué, comprenant la suppression des emojis et des mentions de MBTI dans le texte. Ensuite, la lemmatisation a été réalisée à l'aide de Spacy. Enfin, la question s'est posée de savoir s'il faut utiliser les mots vides (stop words) pour le corpus. Conformément à l'hypothèse 3, qui suggère que la suppression des mots vides pourrait diminuer les performances du modèle, nous avons choisi d'entraîner le modèle en utilisant deux corpus différents : l'un avec les mots vides et l'autre sans.

2) Choix et entraînement du modèle

Référence a été faite au code d'un projet pour l'identification des commentaires positifs et négatifs. Trois modèles ont été explorés : le TFIDFVectorizer de scikit-learn, Word2vec et Camembert. Après plusieurs essais, il est apparu que, en raison de la taille du corpus assez limitée, TFIDF et Word2vec génèrent plus fréquemment des résultats insatisfaisants, où la précision, le rappel et la F1-score sont tous égaux à zéro pour une catégorie donnée de la dimension. Cette situation est moins fréquente avec Camembert. Par conséquent, ce modèle a été sélectionné pour notre corpus.

3) Évaluation de CamemBERT

L'observation des métriques d'évaluation pour le modèle CamemBERT démontre une supériorité marquée des résultats obtenus à partir des corpus de questionnaires par rapport à ceux issus de Twitter, indépendamment de la préservation des mots vides. Cette tendance générale est cohérente à travers les quatre dimensions du MBTI analysées.

Le corpus de questionnaires, particulièrement lorsque les mots vides sont conservés, semble offrir un contexte linguistique plus riche et plus nuancé, ce qui est essentiel pour la précision des prédictions du modèle CamemBERT. Les réponses de questionnaires, plus structurées et réfléchies, pourraient contenir des indices plus explicites et variés concernant les types de personnalité, facilitant ainsi la tâche du modèle dans la classification des traits MBTI.

Accuracy 0.81 0.68 0.6 0.71 Accuracy 0.43 0.38 0.81 0.7 Précision 0.67 0.6 0.86 0.75 Précision 0.57 0.38 0.81 0 Rappel 0.8 0.86 0.43 0.43 Rappel 0.4 1 1 0	Matrice					Matrice				
Précision 0.67 0.6 0.86 0.75 Précision 0.57 0.38 0.81 0 Rappel 0.8 0.86 0.43 0.43 0.43 1 1 0		T-s	T-ns	Q-s	Q-ns		T-s	T-ns	Q-s	Q-ns
Rappel 0.8 0.86 0.43 0.43 Rappel 0.4 1 1 0	Accuracy	0.81	0.68	0.6	0.71	Accuracy	0.43	0.38	0.81	0.71
Карреі 0.0 0.00 0.45 0.45	Précision	0.67	0.6	0.86	0.75	Précision	0.57	0.38	0.81	0
F-score 0.47 0.55 0.89 0	Rappel	0.8	0.86	0.43	0.43	Rappel	0.4	1	1	0
F-score 0.73 0.71 0.57 0.55	F-score	0.73	0.71	0.57	0.55	F-score	0.47	0.55	0.89	0

image 7 : Evaluation camemBERT EI

image 8 : Evaluation camemBERT NS

Matrice					Matrice				
	T-s	T-ns	Q-s	Q-ns		T-s	T-ns	Q-s	Q-ns
Accuracy	0.56	0.36	0.7	0.76	Accuracy	0.5	0.5	0.63	0.41
Précision	0.58	0	0.7	0	Précision	0.46	0.5	0.63	0.45
Rappel	0.78	0	1	0	Rappel	0.86	0.38	1	0.56
F-score	0.67	0	0.82	0	F-score	0.6	0.43	0.77	0.5

image 9: Evaluation camemBERT FT

image 10: Evaluation camemBERT PJ

En contraste, les textes de Twitter présentent souvent une nature plus fragmentaire et éphémère, avec une propension à l'usage de langage informel et de jargon spécifique à la plateforme, qui peuvent diluer les signaux pertinents pour l'analyse psycholinguistique. De plus, la restriction de caractères sur Twitter pourrait contraindre l'expression complète des traits de personnalité, aboutissant à des scores inférieurs en termes de précision, de rappel et de F-score par rapport aux données des questionnaires.

Cette distinction est plus prononcée pour la dimension EI, où le corpus de questionnaires excelle, mettant en lumière la capacité du modèle à capter des signaux d'extraversion et d'introversion plus complexes et plus diversifiés dans des réponses plus élaborées. En revanche, pour la dimension JP, bien que les résultats soient globalement plus faibles, la différence entre les deux sources de données reste significative, soulignant l'impact du type de données sur la performance du modèle.

Ces observations attestent de l'importance de la sélection des données et de leur préparation pour la classification automatique des types de personnalité MBTI. Elles ouvrent également la voie à une exploration plus approfondie des méthodes d'annotation et de modélisation qui pourraient mieux s'adapter aux spécificités de différentes sources de données textuelles.

Conclusion

Selon notre analyse, l'impact de la conservation des mots vides sur les performances est indéniable. L'analyse des résultats démontre que leur présence dans le corpus de questionnaire est associée à une amélioration significative des performances du modèle CamemBERT. Cette observation soutient l'idée que les stopwords contribuent à préserver des nuances linguistiques essentielles à la compréhension du contexte et des traits de personnalité, particulièrement dans un cadre aussi nuancé que celui du MBTI.

En comparaison des résultats obtenus entre le corpus de questionnaire et les textes Twitter, une supériorité nette des données issues des questionnaires est évidente. Ces résultats confirment l'hypothèse que les données Twitter, avec leur brièveté et leur stylisation spécifique, pourraient ne pas être suffisamment riches en signaux lexicaux nécessaires à l'identification précise des types MBTI, une tendance qui se manifeste également dans notre corpus en langue française.

La spécificité du langage sur Twitter, marquée par un style direct, l'usage fréquent de la ponctuation expressive et une structure de phrase moins conventionnelle, présente des défis supplémentaires pour la reconnaissance automatique des traits de personnalité. Les tweets, souvent marqués par des erreurs grammaticales et une écriture informelle, peuvent brouiller les signaux lexicaux et syntaxiques que les modèles comme CamemBERT tentent de décrypter. Par conséquent, chaque utilisateur semble plus extraverti qu'il ne l'est peut-être en réalité, une distorsion qui peut fausser l'évaluation de la dimension Extraversion (E) contre Introversion (I).

En termes de précision entre les différentes dimensions MBTI, il est clair que les dimensions Extraversion (E) et Introversion (I) affichent une exactitude supérieure. En revanche, les dimensions Jugement (J) et Perception (P) montrent une précision moindre, ce qui peut être attribué à la complexité intrinsèque de ces traits dans le contexte textuel. La déduction de la manière dont un individu traite et organise les informations externes est manifestement plus complexe et requiert un modèle capable de décoder avec subtilité les indices textuels.

VI. Ouverture

Lors de l'analyse des performances du modèle linguistique et de Camembert, nous envisageons des améliorations potentielles par le biais des approches suivantes :

Pour le corpus :

- Construire un corpus plus vaste et plus équilibré pour réduire le biais des données.
- Établir des corpus dans différentes langues et explorer divers contextes culturels afin de mieux refléter les caractéristiques de personnalité propres à différentes régions et pays.

Du côté de la machine :

• Effectuer des ajustements supplémentaires des paramètres du modèle CamemBERT pour optimiser les résultats.

• Explorer d'autres modèles de deep learning pré-entraînés.

Ces approches pourraient contribuer à une amélioration significative des performances des modèles.